

# BEYİN BİLGİSAYAR ARAYÜZÜ VERİSİNDE ÖZNETELİK SEÇİMİ VE SINIFLANDIRMA

## FEATURE SELECTION AND CLASSIFICATION ON BRAIN COMPUTER INTERFACE (BCI) DATA

Davut Polat, Zehra Çataltepe

Bilgisayar Mühendisliği Bölümü  
İstanbul Teknik Üniversitesi  
{polatda,cataltepe}@itu.edu.tr

### ÖZETÇE

*Bu bildiride, ham EEG verisinden çok sayıda öznetelik çıkarılıp ve sonrasında hayali motor hareketler kullanılarak gerçekleştirilen beyin bilgisayar arayüzü uygulamaları için öznetelik seçimi ve sınıflandırma yapılmıştır. Öznetelik seçimi yöntemi olarak ilişkiselliği çok ve gereksizliği az olan öznetelik kümesini çok hızlı bir şekilde seçen mRMR (minimum gereksizlik maksimum ilişkiselilik) yöntemi kullanılmıştır. Öznetelik seçiminin, çeşitli sınıflandırıcılar ile sınıflandırma başarımı artırdığı gözlemlenmiştir. Veri kümesi olarak BCI Competition 2003 3A veri kümesi kullanılmıştır.*

### ABSTRACT

*In this paper, a large number of features are extracted from raw EEG data and then feature selection and classification are performed for brain computer interface (BCI) applications using motor imaginary movements. As the feature selection method, mRMR (minimum Redundancy Maximum Relevance) method, which is a fast method to select relevant and non redundant feature set, is chosen. Using a number of different classifiers, it is observed that feature selection helps with the classification performance, higher classification accuracy is achieved using less features. In the experiments, the BCI Competition 2003 3A data set is used.*

### 1. GİRİŞ

19. yüzyılın sonlarından itibaren biyomedikal alanda çok büyük yenilikler yapılmıştır. Bunlardan bazıları hastalıkları tedavi etmek amaçlı olmakla birlikte bazıları sadece akademik çalışma olarak kalmıştır. Son 30 yılda yapılan bilim kurgu filmlerine konu olmuş, düşünce ile makine kontrolü günümüzde gerçekleştirilmektedir. Vücuttan elektrotlarla alınan biyosinyaller işlenip sınıflandırılarak kişinin düşündüğü ve gerçekleştirmek istediği eylem robot veya makineye yaptırılabilir. Bu amaçla kişiden alınan EEG sinyalleri kullanılmaktadır. Beyin bilgisayar arayüzü ile duyma, görme ya da hareket edebilme temelli hastalıkları olan bireylerin yaşayışlarını kolaylaştırmak için araştırmalar yürütülmektedir. Örneğin kolu olmayan bir birey için tasarlanan bir robot kolu beynin duyuusal motor fonksiyonları sayesinde kontrol edebilir. Bunun dışında donanımlara çeşitli komutları gönderebilmek için de beyin bilgisayar arayüzü kullanılabilir. Bilgisayarın fare imlecini EEG sinyalleri kullanılarak hareket ettirilebilmek

buna örnek olarak verilebilir [1].

BCI (beyin bilgisayar arayüzü), beyin aktivitesi ile robot/makine arasındaki iletişimidir. Bu amaçla kişilerin işlenen EEG sinyallerinden komut belirlenip buna uygun işlemler yapılır. BCI için herhangi bir kas hareketi gerekmez bu yüzden felçli insanlar için düşünce ile kontrol edebildikleri tekerlekli sandalyeler yapılabilmektedir[1]. Ayrıca kaza sonucunda komaya giren bir kişinin bilincinin yerinde olduğunu tespit etmek için de BCI sistemler tıp dünyasında kullanılmaktadır. Örneğin komadaki hasta görmediği bir imleci belirli hayali hareketleri düşünerek yukarı-aşağı hareket ettirerek doktorların sordukları soruları evet-hayır şeklinde yanıtlayabilir.

Hangi amaçla kullanılırsa kullanılsın, EEG verisinden hangi özneteliklerin çıkarılacağı ve bunların hangilerinin kullanılacağı verilmesi gereken bir karardır. Daha önce EEG verisi üzerinde öznetelik seçme ve sınıflandırma üzerinde yapılan çalışmalardan [2] EEG verisinden çok sayıda öznetelik çıkarıp mRMR ve PCA (Principal Component Analysis) öznetelik indirgeme yöntemlerini epilepsi sınıflandırma için kullanılmıştır.

Bildirinin 2. Bölüm'ünde ön işleme, 3. Bölüm'ünde çıkartılan öznetelikler, 4. Bölüm'ünde kullanılan öznetelik seçimi algoritması, 5. Bölüm'ünde sınıflandırma ve son bölümünde elde edilen test başarımları ele alınacaktır.

### 2. VERİ KÜMESİ ve ÖN İŞLEME

Bu çalışmada, hayali sol kol, sağ kol, dil ve ayak hareketlerini içeren BCI Competition 2003 deki Graz dataset 2A [3] verisi kullanılmıştır. 3 kişiden (K3b,K6b ve I1b) 1 oturumda veri alınmıştır. Herbir oturumda 45'i sol kol, 45'i sağ kol, 45'i dil ve 45'i ayakları hareket ettiğini hayal ederek alınan veriler vardır. Bir sınıf (sol kol, sağ kol, dil, ayak) için kayıt alınmadan önce bip sesi ile uyarı verilmektedir ve 0-2. saniye arasında ekranda yön oku belirir. 2. Saniyeden sonra katılımcı yönün karşılığındaki hareketin hayalini 6. saniyeye kadar gerçekleştirir. 6. saniyeden sonra siyah ekran çıkarak kayıt sona erer.

EEG kaydı alınan cihazda 60 adet Ag/AgCl elektrotları bulunmaktadır. Alınan sinyaller 250 Hz ile örneklenmiştir. EEG sinyalinin kendisi gürültüdür bu sebeple uyarılmış potansiyelleri yada içeriğindeki bilgiyi ayırt etmek için ham EEG verisinin işlenmesi gerekir. Uyarılmış potansiyeller için, arka arkaya alınmış EEG kayıtlarının ortalaması alınarak uyarıya verilen tepki elde edilebilir. Bir diğer yöntem ise EEG verisinin çeşitli ön işlemeden geçirilip sonrasında bazı özneteliklerin elde edilmesidir. İşaret işleme kütüphanesinin barındırdığı kullanışlı öznetelik fonksiyonları zenginliği ve

kodlama kolaylığı sebebiyle çalışmada Biosig [4] Matlab aracı kullanılmıştır. 60 adet sensörle kaydedilen EEG verisinin kullanılması sistemin karmaşıklığını arttırmakla birlikte sınıflandırma başarımını azaltacaktır. Bu sebeple işlenmemiş EEG verisi üzerinde boyut düşürme işlemi yapılması gerekir. Bu amaçla CSP (Common Spatial Filter) [5] işlemi gerçekleştirilmiştir. Ayrıca boyut düşürme işleminde bir sınıfın diğer sınıflardan ayırtedilebilmesini kolaylaştırmak için, bu sınıfın varyansını maksimize ederken diğer sınıfların varyansını minimize etmemiz gerekir. Bu işlem 2 sınıf arasında öğreticili olarak yapılmasına rağmen, çok sınıflı problemler için, problem 2'li sınıflara ayrılıp bu işlem yapılır. Herbir sınıf için elde edilen izdüşüm vektörleri birleştirilir ve işlenmemiş EEG verisinin bu vektör üzerinde izdüşümü alınır. Bu izdüşümler sınıflardan birinin diğerinden ayırt etmesine katkısı bakımından sıralanmıştır. Çalışmada karmaşıklığı düşük tutmak için herbir sınıf için ilk 5 izdüşüm alınmıştır. Böylece işlenmemiş EEG kaydının yukarıdaki ifadeler doğrultusunda herbir sınıf için 60x5 lik izdüşüm matrislerinin birleşiminden oluşan 60x20 boyutundaki matris üzerinde izdüşümü alınmıştır. İzdüşüm işleminden sonra 3 tane filtreleme işlemi gerçekleştirilmiştir. 4-12 Hz , 12-20 Hz ve 20-30 Hz bandları filtrelenip bir sonraki aşamada filtrelenen veri üzerinden öznitelikler çıkartılmıştır.

### 3. ÖZNİTELİK ÇIKARIMI

BCI alanında yapılan çalışmalarda, farklı öznitelik kümeleri kullanılmıştır. Bu çalışmada çok sayıda öznitelik çıkarılarak oluşturulan bir genişletilmiş öznitelik kümesi kullanılmıştır. Filtreleme sonrasındaki sinyal 2 adet pencereye bölünmüştür ve herbir pencere boyu 250 örnektir. Ardışık 2 pencere 125 örnek ile örtüşmektedir. Herbir pencereden aşağıdaki öznitelikler çıkartılmıştır.

Tablo 1: Kullanılan Öznitelikler

Öznitelik Adı	Öznitelik Sayısı
Minimum	1
Maksimum	1
Ortalama	1
Varyans	1
Ortalama Eğri Uzunluğu [6]	1
Ortalama Enerji [6]	1
Ortalama Teager Enerjisi [6]	1
Çarpıklık	1
Basıklık	1
Renyi Entropisi [7]	1
Wigner Ville Katsayıları [8]	4
Oto Regresyon Katsayıları	4
Zaman Domeni Parametreleri [9]	6
Spektral Güç Yoğunluğu	25
Dalgacık Katsayıları [10]	41

Filtrelenen herbir veri kümesi için 1800 den fazla öznitelik çıkartılmıştır ve toplamda 5620 adet öznitelik elde edilmiştir.

### 4. ÖZNİTELİK SEÇİMİ

Çalışmada öznitelik seçimi için Hanchuan Peng [11] tarafından geliştirilen, kanser sınıflandırma ve gen seçimi gibi bioinformatik alanda kullandığı ve diğer öznitelik seçme yöntemlerine göre daha iyi sonuç elde edilen mRMR

(minimum Redundancy Maximum Relevance) yöntemi kullanılmıştır.

mRMR yönteminde amaç, seçilen özniteliklerin birbirleri arasındaki ortak bilginin en az seviyede olması ve sınıfları ayırt edebilme gücünün ise en yüksek seviyede olmasıdır. Böylece büyük bir öznitelik kümesinden, sınıflandırmaya katkısı yüksek ve birbirleri ile korelasyonu az olan daha küçük bir öznitelik uzayı elde ederek karmaşıklık azaltılır.

Ayrıklaştırılan iki öznitelik olan x ve y için, p(x) ve p(y) marjinal olasılık fonksiyonu ve p(x,y) bağlantı olasılık dağılımı olmak üzere I(x,y), x ve y nin karşılıklı bilgisidir (mutual information):

$$I(x, y) = \sum_{i,j} p(x_i, y_j) \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)} \quad (1)$$

Karşılıklı bilgi fonksiyonu öznitelikler arasındaki lineer olmayan benzerliklerin de hızlı bir şekilde hesaplanmasını sağlar. mRMR yönteminde seçilen öznitelikler arasındaki gereksizliğin (redundancy, Red) en aza indirgenmesi ve aynı zamanda da sınıf etiketleri ile olan bağlılıklarının da (relevance, Rel) en yüksek seviyede olması istenir:

$$\text{Red} = \frac{1}{|S|^2} \sum_{i,j \in S} I(i, j) \quad \text{Rel} = \frac{1}{|S|} \sum_{i \in S} I(h, i) \quad (2)$$

Bu iki denklem eşit ölçüde önem arz eder birinin minimum, diğerinin ise maksimumuna ulaşılmasının Peng tarafından seçilen yolları şöyledir:

$$\text{MID} = \max(\text{Rel} - \text{Red}) \quad \text{MIQ} = \max(\text{Rel} / \text{Red}) \quad (3)$$

MID (Mutual Information Difference) ve MIQ (Mutual Information Quotient) yöntemlerinin uygulanabilmesi için veri kümesinin ayrıklaştırılmış olması gerekir. Çalışmada veri kümesi  $\pm 0.6$  standart sapma kullanılarak üç farklı değer şeklinde ayrıklaştırılmıştır.

### 5. SINIFLANDIRMA

Sınıflandırma işlemi iki farklı şekilde gerçekleştirilmiştir: Dört sınıfın birden ayrıştırılması ve iki aşamada ikili sınıflandırma yapılması. Dört sınıf birden sınıflandırıldığında, sınıfın, örneğin, yukarı, aşağı, sağ veya sol hareketi, olup olmadığı tek seferde belirlenirken iki aşamada öncelikle örneğin yatay mı yoksa düşey hareketi olduğu ve sonra da örneğin sınıfı belirlenir. Örnek yukarı veya aşağı hareketi ise düşey hareketi, sol veya sağ hareketi ise yatay hareketi olarak sınıflandırılır. Örnek düşey hareketi sınıfında ise sonraki aşamada aşağı mı yoksa yukarı hareketi olduğu tespit edilir benzer şekilde yatay hareketi sınıfında ise ikinci aşamada sağ mı yoksa sol mu hareketi olduğu tespit edilir. Her iki sınıflandırma metodunun performanslarının karşılaştırılabilmesi için Tablo 2’de verilen sınıflandırıcılar kullanılmıştır. Sınıflandırıcıların bazılarında düzenleyici (regularization) parametreleri ile sınıflandırıcı performansları iyileştirilebilirken bazıları için böyle bir parametre bulunmamaktadır. Sınıflandırma aşamasında 10 aşamalı çapraz doğrulama yapılmıştır. Her bir çapraz doğrulama aşamasında herbir katılımcıya ait verinin %90’ı

eğitim ve geriye kalan %10'u test amacıyla kullanılmıştır. Performans metriği olarak test başarımları seçilmiştir.

Tablo 2: Kullanılan Sınıflandırıcılar

4 Sınıflı Durum İçin	2 Aşamalı Durum İçin
Naive Bayesian	Naive Bayesian
LDA	LDA
LMS	LMS
PSVM	PSVM
SVM (Lineer Çekirdek)	SVM (Lineer Çekirdek)
SVM (Polinom Çekirdek)	SVM (Polinom Çekirdek)
SVM (Rbf Çekirdek)	SVM (Rbf Çekirdek)
	Wiener Hopf
	Winnnow [12]

## 6. SONUÇLAR

Tek aşamada dört sınıf için yapılan sınıflandırma işlemi için her bir sınıflandırıcının her bir birey için, MID ve MIQ ile gerçekleştirilen öznelik seçim işlemleri sonucunda elde edilen ortalama test başarımları Tablo 3'te gösterilmiştir.

Tablo 3. Dört sınıflı sınıflandırmada ortalama test başarımları

	K3b		K6b		I1b	
Sınıflandırıcı	Mid	Miq	Mid	Miq	Mid	Miq
Naive B.	0.60	0.72	0.49	0.54	0.52	0.61
LDA	0.60	<b>0.78</b>	0.50	0.56	0.47	0.63
LMS	0.39	0.70	0.32	0.53	0.36	0.57
PSVM	0.60	<b>0.78</b>	0.48	0.55	0.44	0.63
SVM-lineer	<b>0.70</b>	0.74	<b>0.52</b>	<b>0.57</b>	<b>0.58</b>	0.64
SVM-poly	0.68	0.75	<b>0.52</b>	0.56	<b>0.58</b>	<b>0.65</b>
SVM-rbf	<b>0.70</b>	0.74	<b>0.52</b>	0.56	<b>0.58</b>	0.64
<b>Maksimum</b>	<b>0.70</b>	<b>0.78</b>	<b>0.52</b>	<b>0.57</b>	<b>0.58</b>	<b>0.65</b>

SVM sınıflandırıcılar ile belirgin şekilde diğer sınıflandırıcılardan daha yüksek başarımlar elde edilmiştir. Ayrıca miq ile yapılan öznelik seçiminin sınıflandırma başarımlarına katkısı mid ile yapılandırma daha yüksektir. Katılımcılardan K3b'nin, diğer katılımcılara göre BCI için EEG kayıt tecrübesinin daha fazla olması elde edilen başarımlarda kolaylıkla görülebilir.

İki aşamada iki sınıf için yapılan sınıflandırma işleminde birinci aşama olan yatay ve dikey sınıflandırması için her bir sınıflandırıcının MID ve MIQ ile gerçekleştirilen öznelik seçim işlemleri sonucunda elde edilen ortalama test başarımları Tablo 4'te gösterilmiştir.

İki aşamada iki sınıf için yapılan sınıflandırma işleminde ikinci aşama olan sol ve sağ sınıflandırması için her bir sınıflandırıcının MID ve MIQ ile gerçekleştirilen öznelik seçim işlemleri sonucunda elde edilen ortalama test başarımları aşağıdaki Tablo 5'te gösterilmiştir.

İki aşamada iki sınıf için yapılan sınıflandırma işleminde diğer ikinci aşama olan aşağı ve yukarı sınıflandırması için her bir sınıflandırıcının MID ve MIQ ile gerçekleştirilen öznelik seçim işlemleri sonucunda elde edilen ortalama test başarımları aşağıdaki Tablo 6'da gösterilmiştir.

Tablo 4. Yatay-Dikey sınıflandırmasında ortalama test başarımları.

	K3b		K6b		I1b	
Sınıflandırıcı	Mid	Miq	Mid	Miq	Mid	Miq
Naive B.	0.89	0.90	0.71	0.70	0.76	0.75
LDA	<b>0.90</b>	<b>0.91</b>	0.73	<b>0.73</b>	0.75	<b>0.76</b>
LMS	0.87	0.88	0.72	0.71	0.68	0.69
PSVM	<b>0.90</b>	0.90	0.73	<b>0.73</b>	0.75	0.75
SVM-lineer	<b>0.90</b>	<b>0.91</b>	<b>0.74</b>	<b>0.73</b>	0.76	0.75
SVM-poly	<b>0.90</b>	<b>0.91</b>	0.73	0.72	<b>0.77</b>	<b>0.76</b>
SVM-rbf	<b>0.90</b>	<b>0.91</b>	0.72	0.71	0.76	0.75
Wiener Hopf	<b>0.90</b>	<b>0.91</b>	0.73	<b>0.73</b>	0.75	0.74
Winnnow	0.88	0.88	0.67	0.68	0.68	0.70
<b>Maksimum</b>	<b>0.90</b>	<b>0.91</b>	<b>0.74</b>	<b>0.73</b>	<b>0.77</b>	<b>0.76</b>

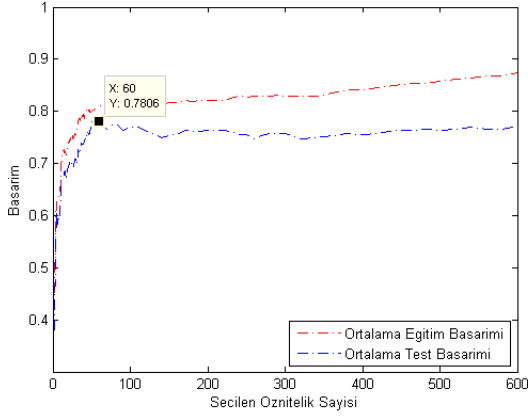
Tablo 5. Sol-Sağ sınıflandırmasında ort. test başarımları.

	K3b		K6b		I1b	
Sınıflandırıcı	Mid	Miq	Mid	Miq	Mid	Miq
Naive B.	0.78	0.76	0.74	0.74	<b>0.77</b>	<b>0.78</b>
LDA	0.82	<b>0.81</b>	0.75	0.75	<b>0.77</b>	<b>0.78</b>
LMS	0.82	<b>0.81</b>	0.72	0.70	0.75	0.75
PSVM	0.81	0.80	0.75	0.76	<b>0.77</b>	<b>0.78</b>
SVM-lineer	0.81	0.80	0.79	0.79	<b>0.77</b>	0.74
SVM-poly	0.81	0.80	0.79	<b>0.81</b>	<b>0.77</b>	0.74
SVM-rbf	0.81	0.80	<b>0.80</b>	0.77	<b>0.77</b>	0.74
Wiener Hopf	<b>0.83</b>	<b>0.81</b>	0.75	0.75	<b>0.77</b>	<b>0.78</b>
Winnnow	0.69	0.72	0.66	0.63	0.70	0.69
<b>Maksimum</b>	<b>0.83</b>	<b>0.81</b>	<b>0.80</b>	<b>0.81</b>	<b>0.77</b>	<b>0.78</b>

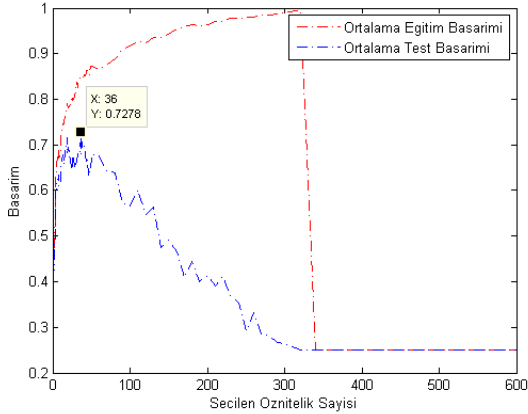
Tablo 6. Yukarı-Aşağı sınıflandırmasında ortalama test başarımları.

	K3b		K6b		I1b	
Sınıflandırıcı	Mid	Miq	Mid	Miq	Mid	Miq
Naive B.	0.78	0.78	<b>0.83</b>	<b>0.85</b>	<b>0.77</b>	0.77
LDA	<b>0.83</b>	<b>0.83</b>	<b>0.83</b>	0.84	<b>0.77</b>	0.80
LMS	0.78	0.79	0.80	0.81	0.75	0.76
PSVM	<b>0.83</b>	0.82	<b>0.83</b>	0.84	<b>0.77</b>	0.81
SVM-lineer	<b>0.83</b>	0.82	0.82	0.82	<b>0.77</b>	0.81
SVM-poly	<b>0.83</b>	<b>0.83</b>	0.82	0.82	<b>0.77</b>	0.82
SVM-rbf	<b>0.83</b>	<b>0.83</b>	0.80	0.80	<b>0.77</b>	<b>0.84</b>
Wiener Hopf	0.82	0.81	<b>0.83</b>	<b>0.85</b>	<b>0.77</b>	0.80
Winnnow	0.70	0.70	0.76	0.75	0.70	0.68
<b>Maksimum</b>	<b>0.83</b>	<b>0.83</b>	<b>0.83</b>	<b>0.85</b>	<b>0.77</b>	<b>0.84</b>

İki aşamada yapılan sınıflandırma sonuçlarını incelediğimizde başarımların yine katılımcıya bağlı olduğunu görmekteyiz. Ayrıca sınıflandırma işleminde sınıflandırıcının başarımını ayarlamak için bir regülasyon parametresinin olması BCI sistemin kararlı olması açısından oldukça önemlidir. Örneğin dört sınıfla yapılan sınıflandırma işleminde K3b katılımcısında, PSVM-Miq için ve Naive Bayesian-Miq için elde edilen sonuçlarda bu durum oldukça net görünmektedir. PSVM için 60'dan fazla öznetelik seçilmesi durumunda başarımlar pek fazla azalmayacaktır; fakat Naive Bayesian için 36'dan fazla öznetelik seçimi durumunda başarımlar çok belirgin bir şekilde düşecektir.



Şekil 1. Dört sınıf için PSVM sınıflandırıcısında MIQ ile seçilen özneteliklerin başarımları.



Şekil 2. Dört sınıf için Naive Bayesian sınıflandırıcısında MIQ ile seçilen özneteliklerin başarımları.

Seçilen özneteliklerin sayısı ve ne oldukları her hasta için farklılık göstermektedir. Fakat genel olarak 150'den az öznetelik ile en iyi test başarımlarına ulaşılabilmektedir. MIQ yöntemine göre seçilmiş ilk özneteliklerin (bkz. Tablo 1) bir kısmı denek bazında Tablo 7'de verilmiştir. Görüldüğü gibi seçilen ilk öznetelikler Tablo 1'deki farklı öznetelik gruplarından gelmiştir. Dolayısıyla genişletilmiş öznetelik kümesi kullanmak gereklidir.

#### Teşekkür

Çalışmayı gerçekleştirirken tecrübelerini benimle paylaşan Onur Varol, Ercan Avşar ve Tuba Ayhan'a ve verimli çalışabilmem için gerekli ortamı sağlayan hocam Müştak Erhan Yalçın'a teşekkür ederim.

Tablo 7. MIQ ile ilk seçilen özneteliklerden bazıları.

K3b	K6b	I1b
Dalgacık Katsayısı	Dalgacık Katsayısı	Spektral Güç Yoğunluğu
Spektral Güç Yoğunluğu	Oto Regresyon Katsayısı	Dalgacık Katsayısı
Dalgacık Katsayısı	Spektral Güç Yoğunluğu	Ortalama Teager Enerjisi
Dalgacık Katsayısı	Ortalama Teager Enerjisi	Dalgacık Katsayısı
Spektral Güç Yoğunluğu	Spektral Güç Yoğunluğu	Spektral Güç Yoğunluğu
Dalgacık Katsayısı	Wigner Ville Katsayıları	Renyi Entropisi

#### 7. KAYNAKÇA

- [1] L. R. Hochberg, M. D. Serruya, G. M. Friehs, "Neuronal ensemble control of prosthetic devices by a human with tetraplegia," *Nature* vol. 442, pp. 164-171, July 2006.
- [2] E. Avşar, M. Ersel Kamaşak, Z. Çataltepe, "Tek-Sınıf Destek Vektör Makineleri Kullanarak EEG İşaretlerinin Sınıflandırılması", *Biyomut* 2009.
- [3] A. Schlögl, O. Filz, H. Ramoser, G. Pfurtscheller, "4 Class EEG Data", *BCI Competition 2003, Graz Data set 3A*, 2004.
- [4] A. Schlögl, BioSig – an open source software library for biomedical signal processing, v4, 2003-2004, software : <http://biosig.sf.net>
- [5] S. Lemm, B. Blankertz, G. Curio, R. Müller, "Spatio-Spectral Filters for Robust Classification of Single Trial EEG," 1999.
- [6] A. B. Gardner, A. M. Krieger, G. Vachtsevanos and B. Litt, "One-Class Novelty Detection for Seizure Analysis from Intracranial EEG," *Journal of Machine Learning Research*, vol. 7, pp. 1025-1044, Dec 2006.
- [7] N. Kannathal, U. Rajendra Acharya, C. M. Lim, and P. K. Sadasivan, "Entropies for detection of epilepsy in EEG," *Computer Methods and Programs in Biomedicine*, vol. 80, issue 1, pp. 17-23, June 2005.
- [8] H. R. Mohseni, A. Maghsoudi and M. B. Shamsollahi, "Seizure Detection in EEG signals: A Comprasion of Different Approaches," 28. *Annual International Conference of IEEE EMBS*, pp. 6724-6727, Aug 2006.
- [9] F. S. Bao, D. Yu-Chun Lie and Y. Zhang, "A New Approach to Automated Epileptic Diagnosis Using EEG and Probabilistic Neural Network," *IEEE ICTAI'08*, pp. 482-486, Nov 2008.
- [10] A. Subaşı, "EEG Signal Classification Using Wavelet Feature Extraction and a Mixture of Expert Model," *Expert Systems with Applications*, vol. 32, issue 4, pp. 1084-1093, May 2007.
- [11] C. Ding, H. Peng, "Minimum Redundancy Feature Selection from Microarray Gene Expression Data," *Proceedings of the IEEE Bioinformatics Conference*, pp. 523-528, Aug 2003.
- [12] N. Littlestone, "Learning Quickly When Irrelevant Attributes Abound: A New Linear-threshold Algorithm," *Machine Learning* pp. 285-318, 1988.